

# Regresión lineal

Laboratorio de Datos, IC - FCEN - UBA - Verano 2026

28 de enero de 2026

¿Qué modelo uso?

## ¿Cómo analizarías estos datos?

---

|   |       |      |        |    |     |   |
|---|-------|------|--------|----|-----|---|
| 0 | 16.99 | 1.01 | Female | No | Sun | 2 |
| 1 | 10.34 | 1.66 | Male   | No | Sun | 3 |
| 2 | 21.01 | 3.50 | Male   | No | Sun | 3 |
| 3 | 23.68 | 3.31 | Male   | No | Sun | 2 |
| 4 | 24.59 | 3.61 | Female | No | Sun | 4 |
| 5 | 25.29 | 4.71 | Male   | No | Sun | 4 |
| 6 | 8.77  | 2.00 | Male   | No | Sun | 2 |
| 7 | 26.88 | 3.12 | Male   | No | Sun | 4 |
| 8 | 15.04 | 1.96 | Male   | No | Sun | 2 |
| : | :     | :    | :      | :  | :   | : |

Primero, **¿qué es un modelo?**


Un modelo es **una representación de fenómenos o procesos del mundo real**. En el contexto de Ciencias de Datos, los modelos son representaciones matemático-computacionales utilizadas para explicar relaciones potencialmente existentes entre las variables de los datos disponibles.

Primero, **¿qué es un modelo?**


Un modelo es **una representación de fenómenos o procesos del mundo real**. En el contexto de Ciencias de Datos, los modelos son representaciones matemático-computacionales utilizadas para explicar relaciones potencialmente existentes entre las variables de los datos disponibles.

**Muchos** factores influyen en la elección del modelo


**¿Cuál es el problema? ¿Cuál es el objetivo del análisis?**



**¿Cuál es el problema? ¿Cuál es el objetivo del análisis?**




¿Cuál es el problema? ¿Cuál es el objetivo del análisis?





¿Cuál es el problema? ¿Cuál es el objetivo del análisis?



- ¿Cuál es el problema? ¿Cuál es el objetivo del análisis?

- ¿Cuál es el problema? ¿Cuál es el objetivo del análisis?
- ¿Qué tipos de variables tengo?

- ¿Cuál es el problema? ¿Cuál es el objetivo del análisis?
- ¿Qué tipos de variables tengo?
- ¿Cuántos datos tengo?

- ¿Cuál es el problema? ¿Cuál es el objetivo del análisis?
- ¿Qué tipos de variables tengo?
- ¿Cuántos datos tengo?
- ¿Tengo muchos outliers? ¿Qué tan robusto debe ser el modelo?

- ¿Cuál es el problema? ¿Cuál es el objetivo del análisis?
- ¿Qué tipos de variables tengo?
- ¿Cuántos datos tengo?
- ¿Tengo muchos outliers? ¿Qué tan robusto debe ser el modelo?
- ¿Con cuántos recursos computacionales cuento?

- ¿Cuál es el problema? ¿Cuál es el objetivo del análisis?
- ¿Qué tipos de variables tengo?
- ¿Cuántos datos tengo?
- ¿Tengo muchos outliers? ¿Qué tan robusto debe ser el modelo?
- ¿Con cuántos recursos computacionales cuento?
- ¿Es importante poder entender cómo el modelo toma decisiones?

# Regresión



# Regresión

Queremos utilizar los datos que tenemos para **buscar relaciones entre ellos** o **estimar datos que no conocemos** o **predecir observaciones futuras**. Los valores a predecir son valores **numéricos**, más precisamente, continuos.


# Regresión

Queremos utilizar los datos que tenemos para **buscar relaciones entre ellos** o **estimar datos que no conocemos** o **predecir observaciones futuras**. Los valores a predecir son valores **numéricos**, más precisamente, continuos.


**Modelo de regresión simple:**  $y = f(x)$



Hay una variable independiente  $x$  y una variable dependiente  $y$ .

**Ejemplo:** estimar el valor de un inmueble a partir de su tamaño ( $m^2$ )






$$y = 2x + 50$$





$$y = 2x + 50$$





¿Qué hacemos ahora?

# Regresión Lineal



# Regresión

Queremos predecir  
un valor continuo

# Lineal

con una función  
lineal (recta)

**Modelo matemático:**  $y = \beta_0 + \beta_1 x$

- $\beta_0$  es la ordenada al origen (llamada también intercept)
- $\beta_1$  es la pendiente
- $x$  es la variable independiente / explicativa / predictora
- $y$  es la variable dependiente / respuesta / a predecir


**Modelo de regresión lineal (simple):**  $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$

- $(x_i, y_i)$  son los datos observados
- $\varepsilon_i$  es un error aleatorio (variación de  $y$  no explicada por  $x$ )
- $\beta_0$  y  $\beta_1$  son **los parámetros del modelo**

**Notación de Wilkinson:**  $y \sim x$

**Residuo:** dados  $\beta_0$  y  $\beta_1$ , definimos al residuo como la diferencia entre el valor observado ( $y_i$ ) y el valor predicho ( $\hat{y}_i$ ):


$$y_i - \underbrace{(\beta_0 + \beta_1 x_i)}_{\hat{y}_i}$$



**Residuo:** dados  $\beta_0$  y  $\beta_1$ , definimos al residuo como la diferencia entre el valor observado ( $y_i$ ) y el valor predicho ( $\hat{y}_i$ ):

$$y_i - \underbrace{(\beta_0 + \beta_1 x_i)}_{\hat{y}_i}$$

→ Queremos encontrar valores para  $\beta_0$  y  $\beta_1$  que minimicen los residuos



Minimizar la suma de los residuos al cuadrado:

$$\begin{aligned}RSS(\beta_0, \beta_1) &= (y_1 - \hat{y}_1)^2 + (y_2 - \hat{y}_2)^2 + \cdots + (y_n - \hat{y}_n)^2 = \\&= (y_1 - (\beta_0 + \beta_1 x_1))^2 + \cdots + (y_n - (\beta_0 + \beta_1 x_n))^2 = \\&= \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_i))^2\end{aligned}$$

Calculamos  $\hat{\beta}_0$  y  $\hat{\beta}_1$  tales que  $\nabla RSS(\hat{\beta}_0, \hat{\beta}_1) = (0, 0)$  :

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$
$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

donde:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$
$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

# ¿Qué tan bien ajusta el modelo?

Vamos a ver dos formas de responder a esta pregunta:

# ¿Qué tan bien ajusta el modelo?

Vamos a ver dos formas de responder a esta pregunta:

- Error Cuadrático Medio



# ¿Qué tan bien ajusta el modelo?

Vamos a ver dos formas de responder a esta pregunta:

- Error Cuadrático Medio
- El coeficiente de determinación  $R^2$

# ¿Qué tan bien ajusta el modelo? ECM

**Error cuadrático medio (ECM):** cuantifica qué tan cerca está un valor predicho del valor real:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \underbrace{(\beta_0 + \beta_1 x_i)}_{\hat{y}_i})^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

# ¿Qué tan bien ajusta el modelo? ECM


**Error cuadrático medio (ECM):** cuantifica qué tan cerca está un valor predicho del valor real:

$$\frac{1}{n} \sum_{i=1}^n (y_i - \underbrace{(\beta_0 + \beta_1 x_i)}_{\hat{y}_i})^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$


Para facilitar la interpretación, usamos la **Raíz del Error Cuadrático Medio (RECM):**

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$


# ¿Qué tan bien ajusta el modelo? Coeficiente de determinación ( $R^2$ )




# ¿Qué tan bien ajusta el modelo? Coeficiente de determinación ( $R^2$ )




# ¿Qué tan bien ajusta el modelo? Coeficiente de determinación ( $R^2$ )



# ¿Qué tan bien ajusta el modelo? Coeficiente de determinación ( $R^2$ )




# ¿Qué tan bien ajusta el modelo? Coeficiente de determinación ( $R^2$ )






# ¿Qué tan bien ajusta el modelo? Coeficiente de determinación ( $R^2$ )



# ¿Qué tan bien ajusta el modelo? Coeficiente de determinación ( $R^2$ )



## Variabilidad del modelo:

|                            |                                        |                                          |
|----------------------------|----------------------------------------|------------------------------------------|
| Variabilidad total:        | $\sum_{i=1}^n (y_i - \bar{y})^2$       | ( $\approx$ Varianza muestral)           |
| Variabilidad no explicada: | $\sum_{i=1}^n (y_i - \hat{y}_i)^2$     | (RSS, suma de cuadrados de los residuos) |
| Variabilidad explicada:    | $\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ |                                          |

## ¿Qué tan bien ajusta el modelo?

La proporción de la variabilidad de  $Y$  explicada por  $X$  se puede explicar como:

$$R^2 = 1 - \frac{\text{Variabilidad no explicada}}{\text{Variabilidad total}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

# ¿Qué tan bien ajusta el modelo?

La proporción de la variabilidad de  $Y$  explicada por  $X$  se puede explicar como:


$$R^2 = 1 - \frac{\text{Variabilidad no explicada}}{\text{Variabilidad total}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

## Observaciones:

- $RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 \geq 0$ , por lo tanto  $R^2 \leq 1$ .
- Si nuestro modelo tiene error total menor que el “modelo constante”,  
 $\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \leq 1$ , por lo tanto  $R^2 \geq 0$ .

**Conclusión:**  $0 \leq R^2 \leq 1$

A mayor  $R^2$  más cercanos están los puntos a la recta, el modelo es mejor.



I DON'T TRUST LINEAR REGRESSIONS WHEN IT'S HARDER  
TO GUESS THE DIRECTION OF THE CORRELATION FROM THE  
SCATTER PLOT THAN TO FIND NEW CONSTELLATIONS ON IT.

