

Laboratorio de Datos

Componentes principales

Verano 2026

Turno noche

Facultad de Ciencias Exactas y Naturales, UBA

Análisis de Componentes Principales (PCA)

- PCA es un método de **aprendizaje no supervisado** para reducir la dimensión de un conjunto de datos (resumir la información que aportan los datos en unas pocas nuevas variables).

Ejemplo. Si quieren dos variables que resuman lo mejor posible la siguiente información de un grupo de futbolistas, ¿cuáles usarían?


- x_1 = cantidad de goles
- x_2 = cantidad de goles en el primer tiempo
- x_3 = cantidad de goles en el segundo tiempo
- x_4 = cantidad de goles ingresando como titular
- x_5 = cantidad de goles ingresando como suplente
- x_6 = cantidad de goles no penales
- x_7 = cantidad de faltas cometidas

Análisis de Componentes Principales (PCA)

- PCA es un método de **aprendizaje no supervisado** para reducir la dimensión de un conjunto de datos (resumir la información que aportan los datos en unas pocas nuevas variables).

Análisis de Componentes Principales (PCA)

- PCA es un método de **aprendizaje no supervisado** para reducir la dimensión de un conjunto de datos (resumir la información que aportan los datos en unas pocas nuevas variables).
- Identifica las direcciones que explican la mayor parte de la variabilidad en los datos (**direcciones principales**).
- Las **componentes principales** son combinaciones lineales de las variables originales.



Componentes Principales - Ejemplo

- Si tenemos un conjunto de datos con 3 variables pero hay dependencia lineal entre las variables (es decir, $ax_1 + bx_2 + cx_3 \approx 0$), al representar a los puntos en el espacio, todos los puntos quedaran ubicados cerca de un plano (el plano $ax_1 + bx_2 + cx_3 = 0$).
- Si proyectamos los puntos sobre ese plano, y consideramos nuevas variables definidas por las coordenadas de las proyecciones en ese plano, estaremos representando las 3 variables originales utilizando solo 2 variables, sin perder mucha información.

Primero: varianza y covarianza

Varianza. Ya vimos la fórmula de varianza para una variable

$x = (x_1, x_2, \dots, x_n)$:

$$\text{var}(x) = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n},$$

donde $\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$ es el promedio o la media de los valores de x .

Recordemos la definición de producto interno entre vectores:

$$\langle x, y \rangle = x_1 y_1 + x_2 y_2 + \dots + x_n y_n = \begin{pmatrix} x_1 & x_2 & \dots & x_n \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = x^T y.$$

Usando productos internos podemos escribir

$$\text{var}(x) = \frac{\langle x - \bar{x}, x - \bar{x} \rangle}{n} = \frac{\|x - \bar{x}\|^2}{n}.$$

Primero: varianza y covarianza

Covarianza. Definimos ahora la covarianza entre dos variables

$x = (x_1, x_2, \dots, x_n)$ e $y = (y_1, y_2, \dots, y_n)$ que mide la relación entre ellas:

$$\text{cov}(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n} = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{n}$$

Interpretación:

- Si $(y_i - \bar{y})$ es siempre positivo cuando $(x_i - \bar{x})$ es positivo, la covarianza será grande positiva.
- Si uno es siempre positivo cuando el otro es negativo, la covarianza será grande negativa.

Correlación

Correlación. Dividiendo la fórmula de covarianza por los desvíos de cada variable obtenemos la fórmula de correlación:

$$\text{corr}(x, y) = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x)}\sqrt{\text{var}(y)}} = \frac{\text{cov}(x, y)}{\sigma(x)\sigma(y)}$$

(estamos *normalizando* la covarianza)


Podemos reescribir esta fórmula:

$$\text{corr}(x, y) = \frac{\frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n}}{\frac{\|x - \bar{x}\|}{\sqrt{n}} \frac{\|y - \bar{y}\|}{\sqrt{n}}} = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|},$$

Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$




La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es

Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$




La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre $x - \bar{x}$ e $y - \bar{y}$.

- Si el ángulo es 0° ,

Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$




La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre $x - \bar{x}$ e $y - \bar{y}$.

- Si el ángulo es 0° , la correlación es 1.
- Si el ángulo es 180° ,

Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$




La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre $x - \bar{x}$ e $y - \bar{y}$.

- Si el ángulo es 0° , la correlación es 1.
- Si el ángulo es 180° , la correlación es -1.
- Si el ángulo es 90° ,

Ángulos y correlación

Recordemos la fórmula para el ángulo entre dos vectores:

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$



La correlación $\text{corr}(x, y) = \frac{\langle x - \bar{x}, y - \bar{y} \rangle}{\|x - \bar{x}\| \|y - \bar{y}\|}$ es el coseno del ángulo entre $x - \bar{x}$ e $y - \bar{y}$.

- Si el ángulo es 0° , la correlación es 1.
- Si el ángulo es 180° , la correlación es -1.
- Si el ángulo es 90° , la correlación es 0.

Matriz de Covarianza

- La matriz de covarianza mide la relación lineal entre dos o más variables.
- Dada una matriz de datos X de n observaciones y p variables, la matriz de covarianza Σ se define como:

$$\Sigma = \frac{(X - \bar{X})^T (X - \bar{X})}{n} \in \mathbb{R}^{p \times p},$$

donde la matriz $\bar{X}$ tiene en cada columna el valor medio de la columna correspondiente de X .

- Si llamamos X^* a la matriz con datos normalizados $X^* = X - \bar{X}$,

$$\Sigma = \frac{(X^*)^T X^*}{n}$$

Matriz de Covarianza

- Definiendo $X^* = X - \bar{X}$,

$$\Sigma = \frac{(X^*)^T X^*}{n}$$



- Las columnas de X^* son las columnas originales de X normalizadas a media 0.
- Cada elemento Σ_{ij} en la matriz de covarianza representa la covarianza entre las variables x^i y x^j ,

$$\text{cov}(x^i, x^j) = \frac{\sum_{k=1}^n (x_k^i - \bar{x}^i)(x_k^j - \bar{x}^j)}{n} = \frac{\langle x^i - \bar{x}^i, x^j - \bar{x}^j \rangle}{n} = \Sigma_{ij}.$$

Proyección de un punto sobre una recta

Retomamos.



Para construir las componentes principales, proyectamos los datos sobre rectas y buscamos la recta para la cual se maximiza la varianza.



Proyección de un punto sobre una recta

Retomamos.

Para construir las componentes principales, proyectamos los datos sobre rectas y buscamos la recta para la cual se maximiza la varianza.



Concepto clave: mayor varianza = mayor información

¿Por qué maximizar la varianza?

- El Análisis de Componentes Principales (PCA) busca encontrar nuevas variables (componentes) que:
 - Sean combinaciones lineales de las variables originales.
 - Expliquen la mayor cantidad de varianza posible.
- La varianza es una medida de la **información contenida** en los datos (si una variable varía poco, no aporta mucha información).
- Al maximizar la varianza de las componentes, se retiene la mayor parte de la estructura de los datos utilizando menos dimensiones.


Longitud de la proyección

La longitud de la proyección de un vector u sobre la recta generada por un vector v es

$$\text{longitud} = \|u\| \cos(\theta) = \frac{\langle u, v \rangle}{\|v\|}.$$

Si $\|v\| = 1$ (vector unitario), obtenemos

$$\text{longitud} = \langle u, v \rangle.$$



Proyección de un conjunto de datos

Si tenemos una matriz de datos $X = \begin{pmatrix} x_1^1 & x_1^2 \\ x_2^1 & x_2^2 \\ \vdots & \vdots \\ x_n^1 & x_n^2 \end{pmatrix}$, el vector de proyecciones sobre

$v = (v_1, v_2)$ (unitario) será simplemente Xv .

$$Xv = \begin{pmatrix} x_1^1 & x_1^2 \\ x_2^1 & x_2^2 \\ \vdots & \vdots \\ x_n^1 & x_n^2 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} x_1^1 \cdot v_1 + x_1^2 \cdot v_2 \\ x_2^1 \cdot v_1 + x_2^2 \cdot v_2 \\ \vdots \\ x_n^1 \cdot v_1 + x_n^2 \cdot v_2 \end{pmatrix} = \begin{pmatrix} \langle (x_1^1, x_1^2), (v_1, v_2) \rangle \\ \langle (x_2^1, x_2^2), (v_1, v_2) \rangle \\ \vdots \\ \langle (x_n^1, x_n^2), (v_1, v_2) \rangle \end{pmatrix}.$$

Varianza de las proyecciones

Si trabajamos con X^* (datos normalizados), las variables tienen media 0, y las proyecciones sobre una recta también tendrán media 0 (ejercicio).

Por lo tanto, podemos calcular la varianza de la proyección sobre la recta generada por v por la fórmula:

$$\text{var}(X^*v) = \frac{\langle X^*v, X^*v \rangle}{n} = \frac{(X^*v)^T (X^*v)}{n} = \frac{v^T (X^*)^T X^* v}{n} = v^T \left(\frac{(X^*)^T X^*}{n} \right) v.$$

Apareció la matriz de covarianza!

$$\text{var}(X^*v) = v^T \Sigma v$$

Primera componente principal

Para encontrar la dirección en la que las proyecciones tienen mayor varianza, debemos encontrar el vector v que maximiza

$$v^T \Sigma v.$$

Teoremas de Álgebra Lineal. La matriz Σ es simétrica, diagonalizable, todos los autovalores son no-negativos y existe una base de autovectores ortogonales.

El vector v que maximiza $v^T \Sigma v$ es el autovector de Σ correspondiente al mayor autovalor.

Este vector v es la dirección de la primera componente principal.

¿Cómo calculamos las demás componentes?

Elegimos las direcciones de forma tal que

- la proyección en la primer dirección tenga la mayor varianza,
- la proyección en la segunda dirección tenga la segunda mayor varianza,
- y así siguiendo,

con la condición adicional de que las direcciones sean perpendiculares. Esto implica que la información contenida en cada proyección sea independiente de las demás proyecciones.

Obtenemos: Las siguientes direcciones corresponden a los autovectores de la matriz de covarianza correspondientes a los demás autovalores ordenados de mayor a menor.

¿Cómo interpretamos cada dirección principal?

- Calculamos las direcciones principales tomando los autovectores de la matriz de covarianza.
- Esto garantiza:

$$\text{cov}(Z_i, Z_j) = 0 \quad \text{para } i \neq j$$

(estamos diagonalizando la matriz de covarianza mediante un cambio de base).

- Esto significa que cada componente aporta **información nueva**, que no estaba presente en las componentes anteriores.
- Como tomamos los autovalores en orden decreciente, maximizamos la varianza en cada paso.

Independencia y perpendicularidad

Recordando la fórmula

$$\text{cov}(X_i, X_j) = \frac{\langle X_i - \overline{X_i}, X_j - \overline{X_j} \rangle}{n}$$


(y usando que las variables Z_i tiene media 0), vemos que $\text{cov}(Z_i, Z_j) = 0$ implica que los vectores Z_i son ortogonales.

Concepto importante:


vectores perpendiculares $\leftrightarrow$ variables independientes

Aclaración: en general, covarianza 0 no implica independencia estadística, pero es una buena señal.

Independencia y covarianza - Ejemplos



Independencia y covarianza - Ejemplos





Covarianza: ≈ 1

Independencia: No

Conocer X nos da
mucho información
sobre Y .

Independencia y covarianza - Ejemplos




Covarianza: ≈ 1

Independencia: No

Conocer X nos da
mucho información
sobre Y .


Independencia y covarianza - Ejemplos



Covarianza: ≈ 1

Independencia: No

Conocer X nos da
mucho información
sobre Y .




Covarianza: ≈ -1


Independencia: No

Conocer X nos da
mucho información
sobre Y .


Independencia y covarianza - Ejemplos




Covarianza: ≈ 1
Independencia: No
Conocer X nos da
mucho información
sobre Y .




Covarianza: ≈ -1
Independencia: No
Conocer X nos da
mucho información
sobre Y .




Independencia y covarianza - Ejemplos



Covarianza: ≈ 1
Independencia: No
Conocer X nos da mucha información sobre Y .




Covarianza: ≈ -1
Independencia: No
Conocer X nos da mucha información sobre Y .




Covarianza: 0
Independencia: Sí
Conocer X no nos da información sobre Y .

Independencia y covarianza - Ejemplos



Independencia y covarianza - Ejemplos





Covarianza: 0

Independencia: No

Conocer X nos da información sobre el rango en el que se mueve Y .

Independencia y covarianza - Ejemplos




Covarianza: 0

Independencia: No

Conocer X nos da información sobre el rango en el que se mueve Y .


Independencia y covarianza - Ejemplos



Covarianza: 0

Independencia: No

Conocer X nos da información sobre el rango en el que se mueve Y .



Covarianza: 0

Independencia: No

Conocer X nos da información sobre Y .

Cálculo de PCA

Repasamos los pasos para calcular las componentes principales utilizando la matriz de covarianza.

- 1 Calculamos la matriz $X^* = X - \bar{X}$ de datos normalizados (a media 0).
- 2 Calculamos la matriz de covarianza $\Sigma = \frac{(X^*)^T X^*}{n} \in \mathbb{R}^{p \times p}$.
- 3 Calculamos los autovalores de Σ : $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p \geq 0$ y los correspondientes autovectores $u_1, \dots, u_p$ (de norma 1).
- 4 Definimos las nuevas variables $z_i = X^* u_i$ (las proyecciones de los datos sobre las direcciones principales).
- 5 Si U es la matriz de autovectores, el nuevo conjunto de datos es $Z = X^* U$ (las nuevas variables son las columnas de Z).

Varianza explicada

- Los autovalores de la matriz de covarianza indican la cantidad de varianza explicada por cada componente principal.

Ejemplo: Si los autovalores de la matriz de covarianza son

$$\lambda_1 = 30, \lambda_2 = 8, \lambda_3 = 2,$$

definimos la varianza total como la suma $\lambda_1 + \lambda_2 + \lambda_3 = 30 + 8 + 2 = 40$.

El porcentaje explicado por cada componente sera el valor de cada autovalor dividido por la varianza total.

Los porcentajes de varianza explicada son

$$\frac{30}{40} = 0.75, \frac{8}{40} = 0.2 \text{ y } \frac{2}{40} = 0.05.$$

Varianza explicada acumulada

Los porcentajes de varianza explicada son

$$\frac{30}{40} = 0.75, \frac{8}{40} = 0.2 \text{ y } \frac{2}{40} = 0.05.$$

Si consideramos las dos primeras componentes, tendremos un total de varianza explicada

$$0.75 + 0.2 = 0.95.$$

Es decir, que si utilizamos las dos primeras componentes, perdemos solo un 5 % de información.

De esta forma podemos reducir la dimensión de los datos, podemos quedarnos con solo estas dos componentes sin perder mucha información.

Ventajas de PCA

- Reducción de dimensionalidad: Permite trabajar con menos variables sin perder mucha información.
- Eliminación de redundancia: Los componentes principales son ortogonales entre sí, eliminando la multicolinealidad.
- Mejora del rendimiento de los algoritmos: Menos variables pueden resultar en tiempos de computación más rápidos.